

**Universidad Politécnica de Yucatán**

Ingeniería en Datos e Inteligencia Artificial

---

**Optimización de Inventario y  
Automatización de Estrategias de Venta  
mediante Ingeniería de Datos e  
Inteligencia Artificial**

Proyecto de Estadía Profesional - TSU

**Autor**

---

**Roberto Vargas Cervera**

Julio 2026

## 1. Planteamiento del Problema

---

Actualmente, la empresa Vinilos enfrenta dificultades para desplazar productos de baja rotación, generando acumulación de material rezagado. Adicionalmente, los esfuerzos de ventas directas pierden efectividad debido al uso de guiones genéricos en llamadas telefónicas, las cuales a menudo no son contestadas por los prospectos.

Existe la necesidad crítica de aprovechar la base de datos histórica para identificar a los clientes con mayor probabilidad de adquirir productos específicos, particularmente aquellos en rezago. Asimismo, se requiere transicionar hacia canales de contacto asíncronos más efectivos, como WhatsApp, utilizando mensajes personalizados que optimicen el tiempo y los recursos del área de ventas, aumentando así la tasa de conversión.

## 2. Objetivo General

---

Desarrollar e implementar un sistema integral de análisis de datos y automatización que permita extraer información de valor del inventario e historial de clientes de la empresa, para optimizar las estrategias de venta. El proyecto contempla el diseño de un pipeline ETL que clasifique productos rezagados (sin ventas en 3 meses, o con exceso de stock y 1 mes sin ventas), la implementación de un modelo de aprendizaje automático (Random Forest) para predecir la probabilidad de recompra en dos segmentos (clientes de alta conversión general y clientes afines a productos rezagados), y la automatización en la nube de guiones de venta personalizados mediante una API de procesamiento de lenguaje natural (Free Tier), inyectando variables clave (nombre, producto y descuento) para su distribución vía WhatsApp.

## 3. Objetivos Específicos

---

Para alcanzar el objetivo general, se ejecutarán los siguientes pasos técnicos:

1. **Construir un pipeline ETL:** Desarrollo de rutinas en Python para la extracción, limpieza y transformación de los datos desde el *[Sistema Actual, ej. Microsip]* de la empresa, definiendo programáticamente los productos rezagados según las reglas de negocio establecidas.
2. **Entrenar un modelo de predicción:** Implementación de un modelo de Machine Learning (Random Forest) para clasificar y puntuar a los clientes en función de su probabilidad de adquirir material estancado o generar ventas de alta conversión.
3. **Automatizar el contacto con el cliente:** Integración de una API de un modelo de lenguaje (Free Tier) mediante un entorno de línea de comandos

(CLI) de diseño propio, para generar guiones de venta dinámicos, teniendo como métrica de éxito la reducción medible del tiempo que el personal de ventas invierte en el contacto inicial.

4. **Desarrollar tableros de visualización:** Diseño de dashboards interactivos utilizando Streamlit Dashboard para reportar los productos rezagados y el rendimiento de las predicciones en tiempo real.

## 4. Justificación

---

El inventario inmovilizado representa un costo de oportunidad significativo para Vinilos. Si bien la empresa registra sus operaciones en su *[Sistema Actual]*, la explotación de esta información histórica es limitada. Al depender de llamadas telefónicas manuales con guiones genéricos, se invierte demasiado tiempo con una baja tasa de respuesta. Este proyecto se justifica al proporcionar una transición tecnológica hacia un enfoque basado en datos (Data-Driven); automatizando la prospección y migrando el contacto hacia WhatsApp con mensajes altamente personalizados. Esto no solo aumentará las probabilidades de liquidar el inventario rezagado, sino que reducirá drásticamente el tiempo operativo invertido por el equipo de ventas.

## 5. Alcance y Fases del Proyecto

---

El proyecto tendrá una duración total de **600 horas**, distribuidas a lo largo de la estadía profesional. Para facilitar la integración con la empresa, se operará bajo un **esquema de trabajo híbrido (80 % remoto y 20 % presencial)**, desarrollando la mayor parte de la arquitectura técnica desde mi entorno local en Fedora Linux.

El trabajo se divide en cuatro fases principales, cuyas horas son estimaciones iniciales sujetas a ajustes ágiles conforme los descubrimientos técnicos lo requieran:

- **Fase 1: Análisis de Datos y Desarrollo ETL (150 horas estimadas).** Exploración de la base de datos y programación de los flujos de extracción.
- **Fase 2: Modelado Predictivo (150 horas estimadas).** Entrenamiento, ajuste de hiperparámetros y validación del modelo Random Forest.
- **Fase 3: Automatización Generativa (150 horas estimadas).** Desarrollo del CLI, integración de la API del LLM y generación de \*prompts\* parametrizados.
- **Fase 4: Visualización y Despliegue (150 horas estimadas).** Construcción de los dashboards, pruebas en el entorno de la empresa y entrega del proyecto.

## 6. Metodología de Trabajo

---

La gestión del proyecto se llevará a cabo mediante una adaptación de la metodología ágil Kanban. Esta elección permite un flujo de trabajo continuo (integrado por las columnas *Por Hacer*, *En Progreso* y *Hecho*), optimizando la visualización de cuellos de botella durante el desarrollo de software.

Para cumplir con los lineamientos académicos, los hitos del tablero Kanban se sincronizarán estratégicamente con las fechas de evaluación periódicas exigidas por la universidad: 9 de octubre (cierre de extracción ETL), 30 de octubre (validación del modelo), 20 de noviembre (integración LLM) y 4 de diciembre de 2026 (despliegue final).

## 7. Marco Tecnológico y Fundamentación

---

El ecosistema tecnológico del proyecto está diseñado para ser robusto, escalable y eficiente. A continuación, se detallan las herramientas y su justificación:

- **Entorno y Control de Versiones:** El desarrollo íntegro se realizará sobre el sistema operativo Fedora Linux, garantizando un entorno nativo estable para herramientas de datos. El control de versiones del código fuente se gestionará a través de Git y repositorios en GitHub.
- **Orquestación y Flujo de Trabajo:** Se utilizará *antigravity* como orquestador principal del proyecto, acompañado de *antigravity CLI* como parte de la suite de desarrollo. Estas herramientas permitirán automatizar la ejecución secuencial del ETL, el entrenamiento y la generación de guiones desde la terminal, minimizando la intervención manual.
- **Procesamiento y Modelado (Random Forest):** Se utilizará Python junto con las librerías Pandas y Scikit-learn. El núcleo predictivo será un algoritmo de *Random Forest* (Bosques Aleatorios). Teóricamente, este modelo es un ensamble estadístico que construye múltiples árboles de decisión durante el entrenamiento y genera la clase que es la moda de las predicciones individuales. Su relevancia para este proyecto radica en su excepcional rendimiento con datos tabulares (bases de datos relacionales), su resistencia al sobreajuste (*overfitting*) y su capacidad para identificar qué variables de los clientes tienen mayor peso en la decisión de compra.
- **Automatización Generativa y Nube:** Se consumirá una API de un Modelo de Lenguaje Grande (LLM) en su capa gratuita (Free Tier). El sistema en Python procesará los datos estructurados en formato JSON y los inyectará

como contexto al LLM. Este proceso se ejecutará mediante una arquitectura en la nube (Cloud) ligera, asegurando disponibilidad asíncrona.

- **Interfaz de Usuario (Staff Vinilos):** Los guiones generados y la lista de prospectos se enviarán directamente a un *dashboard* web interactivo construido con Streamlit. Esta interfaz actuará como puente, permitiendo al personal de ventas visualizar al cliente, el producto sugerido y copiar el guión optimizado para enviarlo inmediatamente por WhatsApp.

## 8. Entregables

---

El proyecto contempla dos líneas de entrega distintas según el usuario final:

1. **Para la Universidad Politécnica de Yucatán:** Un reporte técnico exhaustivo redactado en formato LaTeX, el cual documentará la metodología, fundamentos matemáticos/teóricos, código estructurado y conclusiones de la estadía profesional.
2. **Para la Empresa (Vinilos):** El despliegue de una solución funcional y empaquetada que incluye el dashboard de Streamlit, el modelo predictivo y la orquestación CLI. El sistema se entregará en un formato operativo independiente para las tareas definidas en el alcance actual. Por diseño arquitectónico, cualquier requerimiento futuro, tales como integraciones con nuevas bases de datos, reentrenamiento del modelo tras cambios drásticos en el mercado o el escalamiento hacia nuevas sucursales, requerirá de servicios de consultoría técnica especializada para su adaptación.

## 9. Esquema Conceptual de la Base de Datos

---

Dado que el acceso final a la base de datos se encuentra en fase de consolidación, se ha diseñado un esquema conceptual proyectado que servirá como insumo para el pipeline ETL y el modelo predictivo. Este esquema contempla la extracción de tres entidades principales:

- **Entidad Clientes:** Almacenará identificadores únicos, datos de contacto (WhatsApp) y métricas de comportamiento agregado (frecuencia de compra, valor promedio de vida del cliente).
- **Entidad Historial de Ventas:** Contendrá el registro transaccional detallado. Variables clave incluyen: `ID_Transaccion`, `Fecha_Compra`, `ID_Producto`, y `Monto_Total`. Esta tabla permitirá calcular la recencia (días desde la última compra).

- **Entidad Inventario:** Identificará el catálogo de productos con variables como `Nivel_Stock`, `Fecha_Ultima_Salida` y `Categoria_Producto`. Las reglas de negocio (ej. > 3 meses sin ventas) se aplicarán sobre esta tabla para etiquetar el "material rezagado".

## 10. Gestión de Riesgos

---

Para garantizar el éxito y la viabilidad del proyecto durante las 600 horas establecidas, se han identificado los siguientes riesgos técnicos y sus respectivas estrategias de mitigación:

1. **Calidad e Inaccesibilidad de Datos:** *Riesgo:* Que la base de datos del [Sistema Actual] carezca de integridad referencial o tenga registros incompletos. *Mitigación:* El pipeline ETL incluirá rutinas de imputación de datos nulos y eliminación de valores atípicos. Durante el desarrollo temprano, se utilizará generación de datos sintéticos (*mock data*) para no detener la programación de los flujos.
2. **Limitaciones de la API del LLM (Free Tier):** *Riesgo:* Alcanzar el límite de peticiones por minuto (Rate Limits) impuesto por el proveedor de la API gratuita. *Mitigación:* Se programará una arquitectura de procesamiento por lotes (*batch processing*) gestionada por el orquestador *antigravity*, introduciendo retrasos controlados (delays) entre peticiones para cumplir con las cuotas del servidor.
3. **Sobreajuste del Modelo Predictivo (Overfitting):** *Riesgo:* Que el modelo Random Forest memorice el historial de ventas y pierda capacidad predictiva con clientes nuevos. *Mitigación:* Se aplicarán técnicas de validación cruzada (*Cross-Validation*) y un estricto ajuste de hiperparámetros (limitando la profundidad máxima de los árboles) utilizando `Scikit-learn`.

## 11. Alineación con Competencias Profesionales

---

El presente proyecto se encuentra estructurado para satisfacer los requisitos académicos del segundo ciclo de formación (Estadía Técnico Superior Universitario) del programa educativo. Particularmente, las actividades a desarrollar se alinean de manera directa con las siguientes competencias específicas:

- **Competencia 3.1:** *Extraer información de valor mediante estrategias de modelado, validación, métodos y técnicas de manejo de datos seguros, automatización, herramientas de software y hardware, para encontrar alternativas de*

*solución*. Esta competencia se cumple integralmente mediante la construcción del pipeline ETL y el entrenamiento del modelo predictivo (Random Forest), procesos que transforman datos transaccionales crudos en predicciones de comportamiento de compra.

- **Competencia 3.2:** *Visualizar información de valor mediante análisis e interpretación de resultados, técnicas de visualización y reporte de los resultados, para contribuir a la toma de decisiones que impacten en la rentabilidad.* Esta competencia se acredita mediante el desarrollo e implementación del dashboard interactivo en Streamlit, el cual traducirá los resultados del modelo de aprendizaje automático en una interfaz accesible para la optimización de las labores de ventas.

## 12. Requerimientos y Recursos Operativos

---

Para garantizar la viabilidad del proyecto y el cumplimiento de los entregables dentro de las 600 horas estipuladas, se requiere la provisión de los siguientes recursos y condiciones por parte de la empresa receptora:

- **Acceso a la Información:** Credenciales con privilegios de *solo lectura* al sistema de gestión interno (ej. Microsip) o, en su defecto, exportaciones periódicas de la base de datos histórica (inventario y ventas) para la ingesta de datos hacia el pipeline ETL.
- **Asignación de Asesor de la Organización:** Designación de una figura responsable por parte de la empresa que fungirá como enlace técnico y operativo. Esta persona será la encargada de validar el avance del proyecto y emitir las evaluaciones periódicas requeridas por la institución académica.
- **Infraestructura de Pruebas de Contacto:** Autorización para disponer de un número telefónico de prueba o integración con un canal de WhatsApp designado, con el fin de realizar pruebas controladas de los guiones de venta generados asincrónicamente por la automatización.

## 13. Impacto Esperado

---

La implementación de este proyecto representará un retorno de inversión (ROI) tangible para Vinilos a través de la optimización estratégica de sus recursos. El impacto esperado se consolida en tres ejes principales:

- **Optimización del Tiempo Operativo:** Se proyecta una reducción significativa en las horas-hombre invertidas por el equipo de ventas en prospección

manual, mitigando la ineficiencia de las llamadas telefónicas genéricas y no contestadas.

- **Incremento en la Tasa de Conversión:** Al focalizar los esfuerzos de ventas en prospectos altamente calificados por el modelo Random Forest, y contactarlos mediante un canal asíncrono de alta adopción como WhatsApp con guiones generados por IA, se espera una mayor receptividad y respuesta por parte de los clientes.
- **Liquidez de Inventario:** El diseño predictivo orientado a productos específicos acelerará el desplazamiento del material rezagado, permitiendo a la empresa recuperar el capital inmovilizado, reducir costos de almacenamiento y mejorar la rotación general de su inventario.